Introduzione E' possibile visualizzare una versione interattiva online al seguente link: https://datalore.jetbrains.com/view/notebook/GQXk2hvnZKIYoLvF0B9nsZ. I dati unidimensionali esaminati sono quelli del peso corporeo nel periodo di due anni e mezzo di un uomo di età 24 attuali. I dati bidimensionali riguardano il peso corporeo della medesima persona nello stesso periodo e le calorie assunte giornalmente. Il peso corporeo è stato registrato con due bilance differenti, una per il primo anno e un'altra nei restanti e quindi vi potrebbe essere una differenza di misura. I dati dei primi mesi sulle calorie assunte non sono molto precisi in quanto la quantità del cibo non veniva pesata, ma approssimata. Allo stato dell'arte, importando i dati da Samsung Health, è possibile visualizzare le proprie statistiche. Questo potrebbe non funzionare in futuro se la forma dei dati venisse cambiata, ossia il parsing dei dati non funzionerebbe più. I commenti sui dati, tuttavia, risulteranno inefficienti in quanto i più significativi non sono dinamici, bensì basati su un campione di esso. Poiché i dati sono molti riguardanti il peso corporeo, circa 500, e sulle calorie assunte, quasi 13000, ne verrà preso un campione calcolato nel seguente modo: Per il peso corporeo, il campione sarà il peso medio delle pesate in ogni settimana. Quindi $x_i = peso medio nella settimana i.$ Per le calorie assunte, il campione sarà la media delle calorie assunte in ogni settimana. Quindi y_i = media delle calorie assunte nella settimana i. Nota: Se nella settimana i non vi sono dati sul peso, essa verrà saltata e quindi anche le rispettive calorie assunte. Si è deciso di usare la media campionaria e non la mediana perché i picchi di valore sono importanti da considerare. Installazione dipendenze In [1]: !pip install matplotlib !pip install pandas Requirement already satisfied: matplotlib in c:\python397\lib\site-packages (3.5.2) Requirement already satisfied: kiwisolver>=1.0.1 in c:\python397\lib\site-packages (from matplotlib) (1.4.2) Requirement already satisfied: pillow>=6.2.0 in c:\python397\lib\site-packages (from matplotlib) (9.1.1) Requirement already satisfied: fonttools>=4.22.0 in c:\python397\lib\site-packages (from matplotlib) (4.33.3) Requirement already satisfied: cycler>=0.10 in c:\python397\lib\site-packages (from matplotlib) (0.11.0) Requirement already satisfied: pyparsing>=2.2.1 in c:\python397\lib\site-packages (from matplotlib) (3.0.9) Requirement already satisfied: numpy>=1.17 in c:\python397\lib\site-packages (from matplotlib) (1.22.4) Requirement already satisfied: python-dateutil>=2.7 in c:\python397\lib\site-packages (from matplotlib) (2.8.2) Requirement already satisfied: packaging>=20.0 in c:\python397\lib\site-packages (from matplotlib) (21.3) Requirement already satisfied: six>=1.5 in c:\python397\lib\site-packages (from python-dateutil>=2.7->matplotli b) (1.16.0) Requirement already satisfied: pandas in c:\python397\lib\site-packages (1.4.2) Requirement already satisfied: python-dateutil>=2.8.1 in c:\python397\lib\site-packages (from pandas) (2.8.2) Requirement already satisfied: numpy>=1.18.5 in c:\python397\lib\site-packages (from pandas) (1.22.4) Requirement already satisfied: pytz>=2020.1 in c:\python397\lib\site-packages (from pandas) (2022.1) Requirement already satisfied: six>=1.5 in c:\python397\lib\site-packages (from python-dateutil>=2.8.1->pandas) In [2]: import matplotlib.pyplot as plt import pandas as pd import csv from math import sqrt plt.rcParams['figure.figsize'] = [8, 6] plt.rcParams['figure.dpi'] = 100 Parsing dei dati del peso corporeo È stato necessario arrotondare i valori del peso corporeo perché altrimenti si avrebbe avuto il numero di modalità del carattere quasi uguale all'ampiezza del dato. with open('peso.csv', 'r') as csvfile: In [3]: reader = csv.reader(csvfile, delimiter=',') peso = [] reader.__next__() reader.__next__() for row in reader: peso.append([row[1], float(row[4])]) df peso = pd.DataFrame(peso, columns=['data', 'peso']) df peso['data'] = pd.to datetime(df peso['data']) df_peso = df_peso.groupby(pd.Grouper(key='data', freq='W')).mean().round(0) df_peso = df_peso.dropna() df_peso = df_peso.reset_index() df peso Out[3]: **0** 2019-12-29 140.0 **1** 2020-01-12 140.0 **2** 2020-01-26 139.0 **3** 2020-02-02 139.0 **4** 2020-02-23 138.0 **115** 2022-06-05 103.0 **116** 2022-06-12 103.0 **117** 2022-06-19 102.0 **118** 2022-06-26 106.0 **119** 2022-07-03 104.0 120 rows × 2 columns In [4]: fig, ax = plt.subplots(figsize=(10, 8)) ax.plot(df peso['data'], df peso['peso']) ax.set title('Peso corporeo nel tempo') ax.set xlabel('Data') ax.set ylabel('Peso corporeo') ax.grid() plt.show() Peso corporeo nel tempo 140 135 130 125 Peso corporeo 120 115 110 105 2020-01 2020-04 2020-07 2020-10 2021-01 2021-04 2021-07 2021-10 2022-01 2022-04 2022-07 Sono state eliminate le settimane in cui non vi erano dati. In [5]: | x = sorted(int(p) for p in df_peso('peso')) n = len(x)print(f'Ampiezza del dato: {n}') for i, x i in enumerate(x): $print(f'x ({i + 1}) = {x i}', end='')$ Ampiezza del dato: 120 $x_{(1)} = 102 x_{(2)} = 102 x_{(3)} = 103 x_{(4)} = 103 x_{(5)} = 103 x_{(6)} = 103 x_{(7)} = 103 x_{(8)} = 103 x_{(9)} = 103 x_{(10)} = 103 x_{(11)} = 10$ \times (12)=103 \times (13)=103 \times (14)=104 \times (15)=104 \times (16)=104 \times (17)=104 \times (18)=104 \times (19)=104 \times (20)=104 \times (21)=104 \times $(22) = 104 \times (23) = 104 \times (24) = 105 \times (25) = 105 \times (26) = 105 \times (27) = 105 \times (28) = 105 \times (29) = 105 \times (30) = 105 \times (31) = 105 \times (31$ $(32) = 105 \text{ x} \\ (33) = 105 \text{ x} \\ (34) = 106 \text{ x} \\ (35) = 106 \text{ x} \\ (36) = 106 \text{ x} \\ (37) = 106 \text{ x} \\ (38) = 106 \text{ x} \\ (39) = 106 \text{ x} \\ (40) = 107 \text{ x} \\ (41) = 107$ $(42) = 108 \ x_{43} = 108 \ x_{43} = 108 \ x_{45} = 108 \ x_{45} = 109 \ x_{46} = 109 \ x_{47} = 110 \ x_{48} = 111 \ x_{49} = 111 \ x_{50} = 112 \ x_{51} = 112 \ x_{51$ $(52) = 113 \ x_{(53)} = 114 \ x_{(54)} = 115 \ x_{(55)} = 116 \ x_{(56)} = 117 \ x_{(57)} = 117 \ x_{(58)} = 117 \ x_{(59)} = 117 \ x_{(60)} = 117 \ x_{(61)} = 117 \ x_{(61)}$ $(62) = 118 \times (63) = 118 \times (64) = 118 \times (65) = 118 \times (66) = 118 \times (67) = 118 \times (68) = 118 \times (69) = 118 \times (70) = 119 \times (71) = 120 \times (71$ $(72)=121 \times (73)=121 \times (74)=121 \times (75)=121 \times (76)=122 \times (77)=122 \times (78)=122 \times (79)=122 \times (80)=122 \times (81)=123 \times (81)=123$ $(82) = 124 \times (83) = 124 \times (84) = 125 \times (85) = 125 \times (86) = 125 \times (86) = 125 \times (87) = 126 \times (88) = 126 \times (89) = 126 \times (90) = 126 \times (91) = 126 \times (9$ $(92) = 126 \times (93) = 127 \times (94) = 127 \times (95) = 127 \times (95) = 127 \times (96) = 128 \times (97) = 128 \times (98) = 129 \times (99) = 129 \times (100) = 129 \times (101) = 130 \times (101) = 128 \times (101) =$ $(102) = 130 \times (103) = 131 \times (104) = 131 \times (105) = 132 \times (106) = 132 \times (107) = 133 \times (108) = 133 \times (109) = 134 \times (110) = 134 \times$ $\overline{11}$)=135 x_(112)=136 x_(113)=137 x_(114)=137 x_(115)=138 x_(116)=138 x_(117)=139 x_(118)=139 x_(119)=140 x_(120) =140Costruzione della tabella delle frequenze Calcolo delle modalità In [6]: $v_x = [x[0]]$ for i in range(1, len(x)): **if** $v \times [-1] != x[i]$: v_x.append(x[i]) k x = len(v x)print(f'Numero di modalità: {k x}') for i, v i in enumerate(v x): print(f'v_{i + 1}={v_i}', end=' ') Numero di modalità: 39 v 1=102 v 2=103 v 3=104 v 4=105 v 5=106 v 6=107 v 7=108 v 8=109 v 9=110 v 10=111 v 11=112 v 12=113 v 13=114 v 1 4=115 v 15=116 v 16=117 v 17=118 v 18=119 v 19=120 v 20=121 v 21=122 v 22=123 v 23=124 v 24=125 v 25=126 v 26=1 27 v 27 = 128 v 28 = 129 v 29 = 130 v 30 = 131 v 31 = 132 v 32 = 133 v 33 = 134 v 34 = 135 v 35 = 136 v 36 = 137 v 37 = 138 v 38 = 139 v 38 = 138 v 38v 39=140Calcolo della frequenza assoluta delle modalità Dalle frequenze assolute si può notare quando si è avuto più difficoltà nella perdita del peso o quando si era stabilizzato per un periodo di tempo. In [7]: $f_x = [1]$ for i in range(1, n): **if** x[i - 1] == x[i]: $f_x[-1] += 1$ else: $f_x.append(1)$ for i, f i in enumerate(f x): print(f'f_{i + 1}={f_i}', end=' ') f 1=2 f 2=11 f 3=10 f 4=10 f 5=6 f 6=2 f 7=3 f 8=2 f 9=1 f 10=2 f 11=2 f 12=1 f 13=1 f 14=1 f 15=1 f 16=6 f 17= 8 f_18=1 f_19=1 f_20=4 f_21=5 f_22=1 f_23=2 f_24=3 f_25=6 f_26=3 f_27=2 f_28=3 f_29=2 f_30=2 f_31=2 f_32=2 f_33 =2 f_34=1 f_35=1 f_36=2 f_37=2 f_38=2 f_39=2 Calcolo della frequenza cumulativa assoluta delle modalità In [8]: $F_x = [f_x[0]]$ for i in range(1, k_x): # Uso della relazione di ricorrenza $F_x.append(F_x[-1] + f_x[i])$ for i, F i in enumerate(F x): print(f'F {i + 1}={F i}', end=' ') F_1=2 F_2=13 F_3=23 F_4=33 F_5=39 F_6=41 F_7=44 F_8=46 F_9=47 F_10=49 F_11=51 F_12=52 F_13=53 F_14=54 F_15=55 F _16=61 F_17=69 F_18=70 F_19=71 F_20=75 F_21=80 F_22=81 F_23=83 F_24=86 F 25=92 F 26=95 F 27=97 F 28=100 F 29=10 2 F_30=104 F_31=106 F_32=108 F_33=110 F_34=111 F_35=112 F_36=114 F_37=116 F_38=118 F_39=120 Calcolo della frequenza relativa delle modalità In [9]: $p_x = []$ for f i in f x: p_x.append(f_i / n) for i, p i in enumerate(p_x): print(f'p_{i + 1}={p_i:.3f}', end=' ') p_1=0.017 p_2=0.092 p_3=0.083 p_4=0.083 p_5=0.050 p_6=0.017 p_7=0.025 p_8=0.017 p_9=0.008 p_10=0.017 p_11=0.017 p_12=0.008 p_13=0.008 p_14=0.008 p_15=0.008 p_16=0.050 p_17=0.067 p_18=0.008 p_19=0.008 p_20=0.033 p_21=0.042 p _22=0.008 p_23=0.017 p_24=0.025 p_25=0.050 p_26=0.025 p_27=0.017 p_28=0.025 p_29=0.017 p_30=0.017 p_31=0.017 p_ 32=0.017 p 33=0.017 p 34=0.008 p 35=0.008 p 36=0.017 p 37=0.017 p 38=0.017 p 39=0.017 Calcolo della frequenza cumulativa relativa delle modalità In [10]: $P_x = []$ for F i in F x: P_x.append(F_i / n) for i, P i in enumerate(P x): print(f'P_{i + 1}={P_i:.3f}', end=' ') P 1=0.017 P 2=0.108 P 3=0.192 P 4=0.275 P 5=0.325 P 6=0.342 P 7=0.367 P 8=0.383 P 9=0.392 P 10=0.408 P 11=0.425 P_12=0.433 P_13=0.442 P_14=0.450 P_15=0.458 P_16=0.508 P_17=0.575 P_18=0.583 P_19=0.592 P_20=0.625 P_21=0.667 P _22=0.675 P_23=0.692 P_24=0.717 P_25=0.767 P_26=0.792 P_27=0.808 P_28=0.833 P_29=0.850 P_30=0.867 P_31=0.883 P_ 32=0.900 P 33=0.917 P 34=0.925 P 35=0.933 P 36=0.950 P 37=0.967 P 38=0.983 P 39=1.000 Tabella delle frequenze In [11]: data table = [] for i in range(k_x): $\label{eq:data_table.append} \texttt{data_table.append}([\texttt{i} + \texttt{1}, \texttt{v}_\texttt{x}[\texttt{i}], \texttt{f}_\texttt{x}[\texttt{i}], \texttt{p}_\texttt{x}[\texttt{i}], \texttt{F}_\texttt{x}[\texttt{i}], \texttt{P}_\texttt{x}[\texttt{i}]])$ df_data_table = pd.DataFrame(data_table, columns=['i', 'v_i', 'f_i', 'p_i', 'F_i', 'P_i']) df_data_table.set_index('i', inplace=True) df_data_table Out[11]: v_i f_i p_i F_i P_i **1** 102 2 0.016667 2 0.016667 **2** 103 11 0.091667 13 0.108333 23 0.191667 **3** 104 10 0.083333 **4** 105 10 0.083333 33 0.275000 **5** 106 6 0.050000 39 0.325000 **6** 107 2 0.016667 41 0.341667 **8** 109 2 0.016667 46 0.383333 1 0.008333 47 0.391667 **9** 110 2 0.016667 49 0.408333 **10** 111 2 0.016667 **11** 112 51 0.425000 **12** 113 1 0.008333 52 0.433333 **13** 114 1 0.008333 53 0.441667 1 0.008333 54 0.450000 **14** 115 **15** 116 1 0.008333 55 0.458333 6 0.050000 **16** 117 61 0.508333 8 0.066667 **17** 118 69 0.575000 **18** 119 1 0.008333 70 0.583333 **19** 120 71 0.591667 1 0.008333 **20** 121 4 0.033333 75 0.625000 **21** 122 5 0.041667 80 0.666667 **22** 123 1 0.008333 81 0.675000 **23** 124 2 0.016667 83 0.691667 **24** 125 3 0.025000 86 0.716667 6 0.050000 92 0.766667 **25** 126 3 0.025000 95 0.791667 **26** 127 2 0.016667 **27** 128 97 0.808333 **28** 129 3 0.025000 100 0.833333 2 0.016667 102 0.850000 **29** 130 **30** 131 2 0.016667 104 0.866667 **31** 132 2 0.016667 106 0.883333 **32** 133 2 0.016667 108 0.900000 **33** 134 2 0.016667 110 0.916667 1 0.008333 111 0.925000 **34** 135 **35** 136 1 0.008333 112 0.933333 **36** 137 2 0.016667 114 0.950000 2 0.016667 116 0.966667 **37** 138 139 2 0.016667 118 0.983333 **39** 140 2 0.016667 120 1.000000 Grafici distribuzione delle frequenze assolute Grafico a linee In [12]: fig, ax = plt.subplots() ax.plot(v x, f x, '-o')ax.set title('Distribuzione delle frequenze assolute') ax.set xlabel(r'\$v i\$') ax.set ylabel(r'\$f i\$') ax.grid() for i, v i in enumerate(v x): $ax.text(v_i, f_x[i], f'\{f_x[i]:.0f\}', ha='left', va='bottom')$ Distribuzione delle frequenze assolute 8 6 4 105 110 115 120 130 135 Istogramma def plot histogram classe(ampiezza classe): In [13]: $min_value = x[0]$ $max_value = x[n - 1]$ fig, ax = plt.subplots() values, bins, bars = ax.hist(x, bins=list(range(min_value, max_value + ampiezza_classe, ampiezza_classe)), ax.set_xticks(bins) ax.bar_label(bars) ax.set_title(f'Distribuzione delle frequenze assolute con classe di ampiezza {ampiezza classe}') ax.set_xlabel(r'\$v_i\$') ax.set_ylabel(r'\$f i\$') plt.show() In [14]: plot_histogram classe(3) Distribuzione delle frequenze assolute con classe di ampiezza 3 20 15 10 5 102 105 108 111 114 117 120 123 126 129 132 135 138 141 In [15]: plot_histogram_classe(5) Distribuzione delle frequenze assolute con classe di ampiezza 5 35 30 25 20 15 10 5 Indici di posizione Calcolo della media campionaria L'indice della media campionare su tutto il campione è poco significativo in questo campione perché, come si nota dal grafico dal peso corporeo nel tempo, il peso sempre sceso e quindi i valori sono cambiati spesso. La media campionaria invece indicherebbe che si è avuto una media di peso corporeo per ogni settimana di 117 kg, cosa non vera. In [16]: $x_{mean} = 0$ for x i in x: x mean += x i x mean = x mean / nprint(f'Media campionaria: {x mean}') Media campionaria: 116.975 Calcolo della media pesata In [17]: $x_{mean_pesata} = 0$ for i in range(k x): $x_{mean_pesata} += (f_x[i] / n) * v_x[i]$ print(f'Media pesata: {x_mean_pesata}') Media pesata: 116.97500000000002 Calcolo della mediana campionaria Anche la mediana campionaria per la tipologia del dato, è poco signficativa. **if** n % 2 == 0: In [18]: x mediana = (x[n // 2] + x[n // 2 - 1]) / 2else: x mediana = x[n // 2]print(f'Mediana campionaria: {x mediana}') Mediana campionaria: 117.0 Calcolo della moda campionaria La moda campionaria è molto utile, in quanto come detto precedentemente, si riesce a determinare in quali fasi del peso corporeo si è avuto più difficoltà. Calcolando più mode campionarie, escludendo ogni volta quella precedente, si riesce a capire quali sono le fasi del peso corporeo in cui si è avuto più difficoltà. In [19]: $\max_{x = 0}$ index = 0count = 0for i, f i in enumerate(f x): if f i > max f x: $\max f x = f i$ count = 1 index = i elif f i == max f x: count += 1 $x \mod = v \times [index]$ if count == 1: print(f'Moda campionaria unimodale: v_{index + 1} = {x_moda}, f_{index + 1} = {max_f_x}') elif count == 2: print(f'Moda campionaria bimodale: v {index + 1} = {x moda}, f {index + 1} = {max f x}') print(f'Moda campionaria multimodale: v {index + 1} = {x moda}, f {index + 1} = {max f x}') Moda campionaria unimodale: v = 103, f = 11Indici di variabilità Calcolo della varianza campionaria La varianza dei dati rispetto alla media campionaria è un po' alta. In [20]: $s2_x = 0$ for x i in x: s2 x += (x i - x mean) ** 2s2 x = s2 x / (n - 1)print(f'Varianza campionaria: {s2 x}') Varianza campionaria: 133.5539915966387 Calcolo della deviazione standard campionaria In [21]: $s_x = sqrt(s2 x)$ print(f'Deviazione standard campionaria: {s_x}') Deviazione standard campionaria: 11.556556216998155 Calcolo dello scarto medio assoluto In [22]: $sa_x = 0$ for x i in x: $sa_x += abs(x_i - x_mean)$ $sa_x = sa_x / n$ print(f'Scarto medio assoluto: {sa x}') Scarto medio assoluto: 10.010416666666688 Calcolo dell'ampiezza del campo di variazione Questo dato indica anche il massimo di chili persi in tutto il periodo. In [23]: $w_x = x[n - 1] - x[0]$ print(f'Ampiezza del campo di variazione: {w x}') Ampiezza del campo di variazione: 38 Calcolo del coefficiente di variazione In [24]: $cv_x = s_x / x mean$ print(f'Coefficiente di variazione: {cv x}') Coefficiente di variazione: 0.09879509482366451 Indici di forma Calcolo dell'indice di simmetria Dall'istogramma si nota una coda a destra, infatti l'indice è positivo. In [25]: $g_x = 0$ for x_i in x: $g_x += (x_i - x_mean) ** 3$ $g_x = g_x / n$ $g_x = g_x / (s_x ** 3)$ **if** g x < 0: print(f'Indice di simmetria: {g_x}, asimmetria negativa') else: print(f'Indice di simmetria: {g_x}, asimmetria positiva') Indice di simmetria: 0.30646667980571396, asimmetria positiva In [26]: plot_histogram_classe(1) Distribuzione delle frequenze assolute con classe di ampiezza 1 10 8 6 4 1012181481612189910111121314191612181990172734959677999931823349596778990Calcolo dell'indice di curtosi In [27]: curtosi x = 0for x i in x: $curtosi_x += (x_i - x_mean) ** 4$ curtosi x = curtosi x / n $curtosi_x = curtosi_x / (s_x ** 4)$ curtosi x = curtosi x - 3if curtosi x > 0: print(f'Indice di curtosi: {curtosi x}, è presente un eccesso di dati nelle classi centrali') elif curtosi x < 0:</pre> print(f'Indice di curtosi: {curtosi x}, è presente una carenza di dati nelle classi centrali') else: print(f'Indice di curtosi: {curtosi_x}, è presente una distribuzione di dati come quella di una distribuzione Indice di curtosi: -1.1994033519694862, è presente una carenza di dati nelle classi centrali Quartili Calcolo dei quartili def get_quartile(k): In [28]: np = n * (k / 100)**if** np % 1 == 0: **return** (x[int(np)] + x[int(np) - 1]) / 2 return x[int(np)] $Q1_x = get_quartile(25)$ $Q2_x = get_quartile(50)$ Q3 x = get quartile (75)print(f'Principali quartili: Q1 = $\{Q1_x\}$, Q2 = $\{Q2_x\}$, Q3 = $\{Q3_x\}$ ') Principali quartili: Q1 = 105.0, Q2 = 117.0, Q3 = 126.0 Calcolo dello scarto interquartile Indica la lunghezza del rettangolo nel box plot In [30]: si x = Q3 x - Q1 xprint(f'Scarto interquartile: {si x}') Scarto interquartile: 21.0 **Box plot** Come si evince dal grafico, non vi sono outliers. Se essi fosse presenti, sarebbero indicati nel grafico come dei punti rossi. Il segmento arancione rappresenta la media campionaria. In [31]: fig, ax = plt.subplots(figsize=(10, 8)) ax.boxplot(x, flierprops=dict(marker='s', markerfacecolor='red')) ax.set title('Box plot') ax.yaxis.set ticks position('none') ax.grid(axis='y', linestyle='-', linewidth=0.5, color='lightgrey') ax.spines['top'].set visible(False) ax.spines['right'].set_visible(False) ax.spines['left'].set_visible(False) ax.get_xaxis().set_visible(False) plt.show() Box plot 135 130 115 Intervalli di previsione Gli intervalli di previsione non sono quelli tipici di una distribuzione normale, ma questo lo si poteva già evincere dall'istogramma delle classi di ampiezza 1. $intervallo1_x = (x_mean - s_x, x_mean + s_x)$ $intervallo2_x = (x_mean - 2 * s_x, x_mean + 2 * s_x)$ $intervallo3_x = (x_mean - 3 * s_x, x_mean + 3 * s_x)$ count1 = 0count2 = 0count3 = 0for x i in x: if intervallo1_x[0] < x_i < intervallo1_x[1]:</pre> count1 += 1 if intervallo2_x[0] < x_i < intervallo2_x[1]:</pre> count2 += 1 if intervallo3_ $x[0] < x_i < intervallo3_<math>x[1]$: count3 += 1 print(f'Intervalli di previsione:\n{intervallo1 x} {(count1 / n) * 100:.2f}%\n{intervallo2 x} {(count2 / n) * 1 Intervalli di previsione: (105.41844378300183, 128.53155621699815) 53.33% (93.86188756600369, 140.08811243399632) 100.00% (82.30533134900553, 151.64466865099445) 100.00% Parsing dei dati delle calorie assunte In [33]: with open('calorie.csv', 'r') as csvfile: reader = csv.reader(csvfile, delimiter=',') calorie = [] reader.__next__() reader.__next__() for row in reader: calorie.append([row[0], float(row[8])]) df_calorie = pd.DataFrame(calorie, columns=['data', 'calorie']) df_calorie['data'] = pd.to_datetime(df_calorie['data']) df_calorie = df_calorie.groupby(pd.Grouper(key='data', freq='D')).sum().round(0) df_calorie = df_calorie.reset_index() df_calorie = df_calorie.groupby(pd.Grouper(key='data', freq='W')).mean().round(0) df_calorie = df_calorie.reset_index() print(f'Numero di ampiezza dei dati prima della eliminazione delle settimane in cui non vi sono state pesate co df calorie Numero di ampiezza dei dati prima della eliminazione delle settimane in cui non vi sono state pesate corporee: Out[33]: data calorie **0** 2019-10-20 2374.0 **1** 2019-10-27 1768.0 **2** 2019-11-03 1291.0 **3** 2019-11-10 1875.0 **4** 2019-11-17 1702.0 **137** 2022-06-05 1808.0 **138** 2022-06-12 1718.0 **139** 2022-06-19 1784.0 **140** 2022-06-26 1960.0 **141** 2022-07-03 2011.0 142 rows × 2 columns In [34]: fig, ax = plt.subplots(figsize=(10, 8)) ax.plot(df_calorie['data'], df_calorie['calorie']) ax.set_title('Calorie assunte nel tempo') ax.set xlabel('Data') ax.set_ylabel('Calorie assunte') ax.grid() plt.show() Calorie assunte nel tempo 2600 2400 2200 2000 Calorie assunte 1800 1600 1400 1200 1000 2020-09 2021-01 2020-05 2021-05 2022-01 2019-09 2020-01 2021-09 In [35]: df_merge = pd.merge(df_peso, df_calorie, on='data', how='inner') df merge = df merge.dropna() df merge = df merge.reset index() print(f'Numero di ampiezza dei dati dopo l\'eliminazione delle settimane in cui non vi sono state pesate corpor df merge Numero di ampiezza dei dati dopo l'eliminazione delle settimane in cui non vi sono state pesate corporee: 120 Out[35]: data peso calorie 0 0 2019-12-29 140.0 1704.0 1 2020-01-12 140.0 1816.0 2 2 2020-01-26 139.0 1813.0 3 2020-02-02 139.0 4 2020-02-23 138.0 1939.0 115 115 2022-06-05 103.0 1808.0 116 116 2022-06-12 103.0 117 117 2022-06-19 102.0 1784.0 118 118 2022-06-26 106.0 1960.0 119 2022-07-03 104.0 2011.0 120 rows × 4 columns Dati bidimensionali Calcolo dei coefficienti di correlazione campionario

```
In [36]: n = len(df_merge)
    peso_mean = df_merge['peso'].mean()
    calorie_mean = df_merge['calorie'].mean()
    s_peso = df_merge['peso'].std()
    s_calorie = df_merge['calorie'].std()

r = 0
    for i in range(n):
        r += (df_merge['peso'][i] - peso_mean) * (df_merge['calorie'][i] - calorie_mean)
    r = r / ((n - 1) * s_peso * s_calorie)

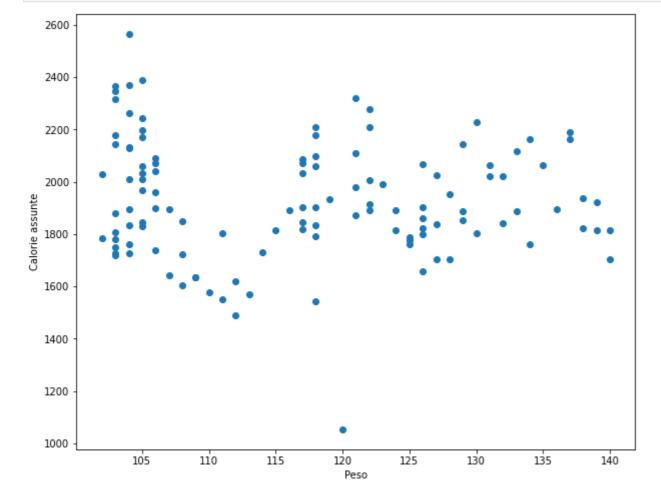
if r > 0:
        print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione positiva')
elif r < 0:
        print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione negativa')
else:
        print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione negativa')</pre>
```

Coefficiente di correlazione campionario: -0.07911156081428679, è presente una correlazione negativa

Diagramma a dispersione (scatter plot)

```
In [37]: fig, ax = plt.subplots(figsize=(10, 8))
    ax.scatter(df_merge['peso'], df_merge['calorie'])
    ax.set_xlabel('Peso')
    ax.set_ylabel('Calorie assunte')

plt.show()
```



Quello che emerge dalla correlazione negativa tra il peso e le calorie è che quando il peso era alto vi era un minore consumo di calorie. Al diminuire del peso, le calorie assunte sono aumentate. In effetti nella realtà questo accadde e quindi si può trovare una delle cause della non diminuzione del peso. Tuttavia, le variabili sono molte, come ad esempio una maggiore attività fisica che ha portato allo sviluppo di massa muscolare e quindi alla contribuzione della non diminuzione del peso in generale.

Con i dati da Samsung Health si potrebbero fare molti altri studi, come ad esempio quanto ha influito l'attività fisica sul peso, come è cambiato il battito cardiaco e la pressione sanguigna (la pressione scese di molto), ecc. Con l'incrocio dei dati si potrebbero fare tante cose interessanti.