Introduzione

E' possibile visualizzare una versione interattiva online al seguente link:
https://datalore.jetbrains.com/view/notebook/IdhFKH2398v0VPZIV9YyIb.

I dati unidimensionali esaminati sono quelli del peso corporeo nel periodo di due anni e mezzo di un uomo di età 24 attuali.
I dati bidimensionali riguardano il peso corporeo della medesima persona nello stesso periodo e le calorie assunte giornalmente.

Il peso corporeo è stato registrato con due bilance differenti, una per il primo anno e un'altra nei restanti e quindi vi potrebbe essere una differenza di misura.
I dati dei primi mesi sulle calorie assunte non sono molto precisi in quanto la quantità del cibo non veniva pesata, ma approssimata.

Allo stato dell'arte, importando i dati da Samsung Health, è possibile visualizzare le proprie statistiche. Questo potrebbe non funzionare in futuro se la forma dei dati venisse cambiata, ossia il parsing dei dati non funzionerebbe più. I commenti sui dati, tuttavia, risulteranno inefficienti in quanto i più significativi non sono dinamici, bensì basati su un campione di esso.

Poiché i dati sono molti riguardanti il peso corporeo, circa 500, e sulle calorie assunte, quasi 13000, ne verrà preso un campione calcolato nel seguente modo:

- Per il peso corporeo, il campione sarà il peso medio delle pesate in ogni settimana.
  Quindi x_i = peso medio nella settimana i.
- Per le calorie assunte, il campione sarà la media delle calorie assunte in ogni settimana.
  Quindi y_i = media delle calorie assunte nella settimana i.

Nota: Se nella settimana i non vi sono dati sul peso, essa verrà saltata e quindi anche le rispettive calorie assunte.

Si è deciso di usare la media campionaria e non la mediana perché i picchi di valore sono importanti da considerare.

Installazione dipendenze

In [75]:
```
!pip install matplotlib
!pip install pandas
```
```
Requirement already satisfied: matplotlib in c:\python397\lib\site-packages (3.5.2)
Requirement already satisfied: python-dateutil>=2.7 in c:\python397\lib\site-packages (from matplotlib) (2.8.2)
Requirement already satisfied: pillow>=6.2.0 in c:\python397\lib\site-packages (from matplotlib) (9.1.1)
Requirement already satisfied: numpy>=1.17 in c:\python397\lib\site-packages (from matplotlib) (1.22.4)
Requirement already satisfied: kiwisolver>=1.0.1 in c:\python397\lib\site-packages (from matplotlib) (1.4.2)
Requirement already satisfied: packaging>=20.0 in c:\python397\lib\site-packages (from matplotlib) (21.3)
Requirement already satisfied: fonttools>=4.22.0 in c:\python397\lib\site-packages (from matplotlib) (4.33.3)
Requirement already satisfied: pyparsing>=2.2.1 in c:\python397\lib\site-packages (from matplotlib) (3.0.9)
Requirement already satisfied: cycler>=0.10 in c:\python397\lib\site-packages (from matplotlib) (0.11.0)
Requirement already satisfied: six>=1.5 in c:\python397\lib\site-packages (from python-dateutil>=2.7->matplotli
b) (1.16.0)
WARNING: There was an error checking the latest version of pip.
Requirement already satisfied: pandas in c:\python397\lib\site-packages (1.4.2)
Requirement already satisfied: numpy>=1.18.5 in c:\python397\lib\site-packages (from pandas) (1.22.4)
Requirement already satisfied: python-dateutil>=2.8.1 in c:\python397\lib\site-packages (from pandas) (2.8.2)
Requirement already satisfied: pytz>=2020.1 in c:\python397\lib\site-packages (from pandas) (2022.1)
Requirement already satisfied: six>=1.5 in c:\python397\lib\site-packages (from python-dateutil>=2.8.1->pandas)
(1.16.0)
WARNING: There was an error checking the latest version of pip.
```

In [76]:
```
import matplotlib.pyplot as plt
import pandas as pd
import csv
from math import sqrt

plt.rcParams['figure.figsize'] = [8, 6]
plt.rcParams['figure.dpi'] = 100
```

Parsing dei dati del peso corporeo

È stato necessario arrotondare i valori del peso corporeo perché altrimenti si avrebbe avuto il numero di modalità del carattere quasi uguale all'ampiezza del dato.

In [77]:
```
with open('peso.csv', 'r') as csvfile:
    reader = csv.reader(csvfile, delimiter=',')
    peso = []
    reader.__next__()
    reader.__next__()
    for row in reader:
        peso.append([row[1], float(row[4])])

df_peso = pd.DataFrame(peso, columns=['data', 'peso'])
df_peso['data'] = pd.to_datetime(df_peso['data'])
df_peso = df_peso.groupby(pd.Grouper(key='data', freq='W')).mean().round(0)
df_peso = df_peso.dropna()
df_peso = df_peso.reset_index()
df_peso
```

Out[77]:

	data	peso
0	2019-12-29	140.0
1	2020-01-12	140.0
2	2020-01-26	139.0
3	2020-02-02	139.0
4	2020-02-23	138.0
...	...	...
112	2022-05-15	104.0
113	2022-05-22	104.0
114	2022-05-29	103.0
115	2022-06-05	103.0
116	2022-06-12	103.0

117 rows × 2 columns

In [78]:
```
fig, ax = plt.subplots(figsize=(10, 8))
ax.plot(df_peso['data'], df_peso['peso'])
ax.set_title('Peso corporeo nel tempo')
ax.set_xlabel('Data')
ax.set_ylabel('Peso corporeo')
ax.grid()
plt.show()
```

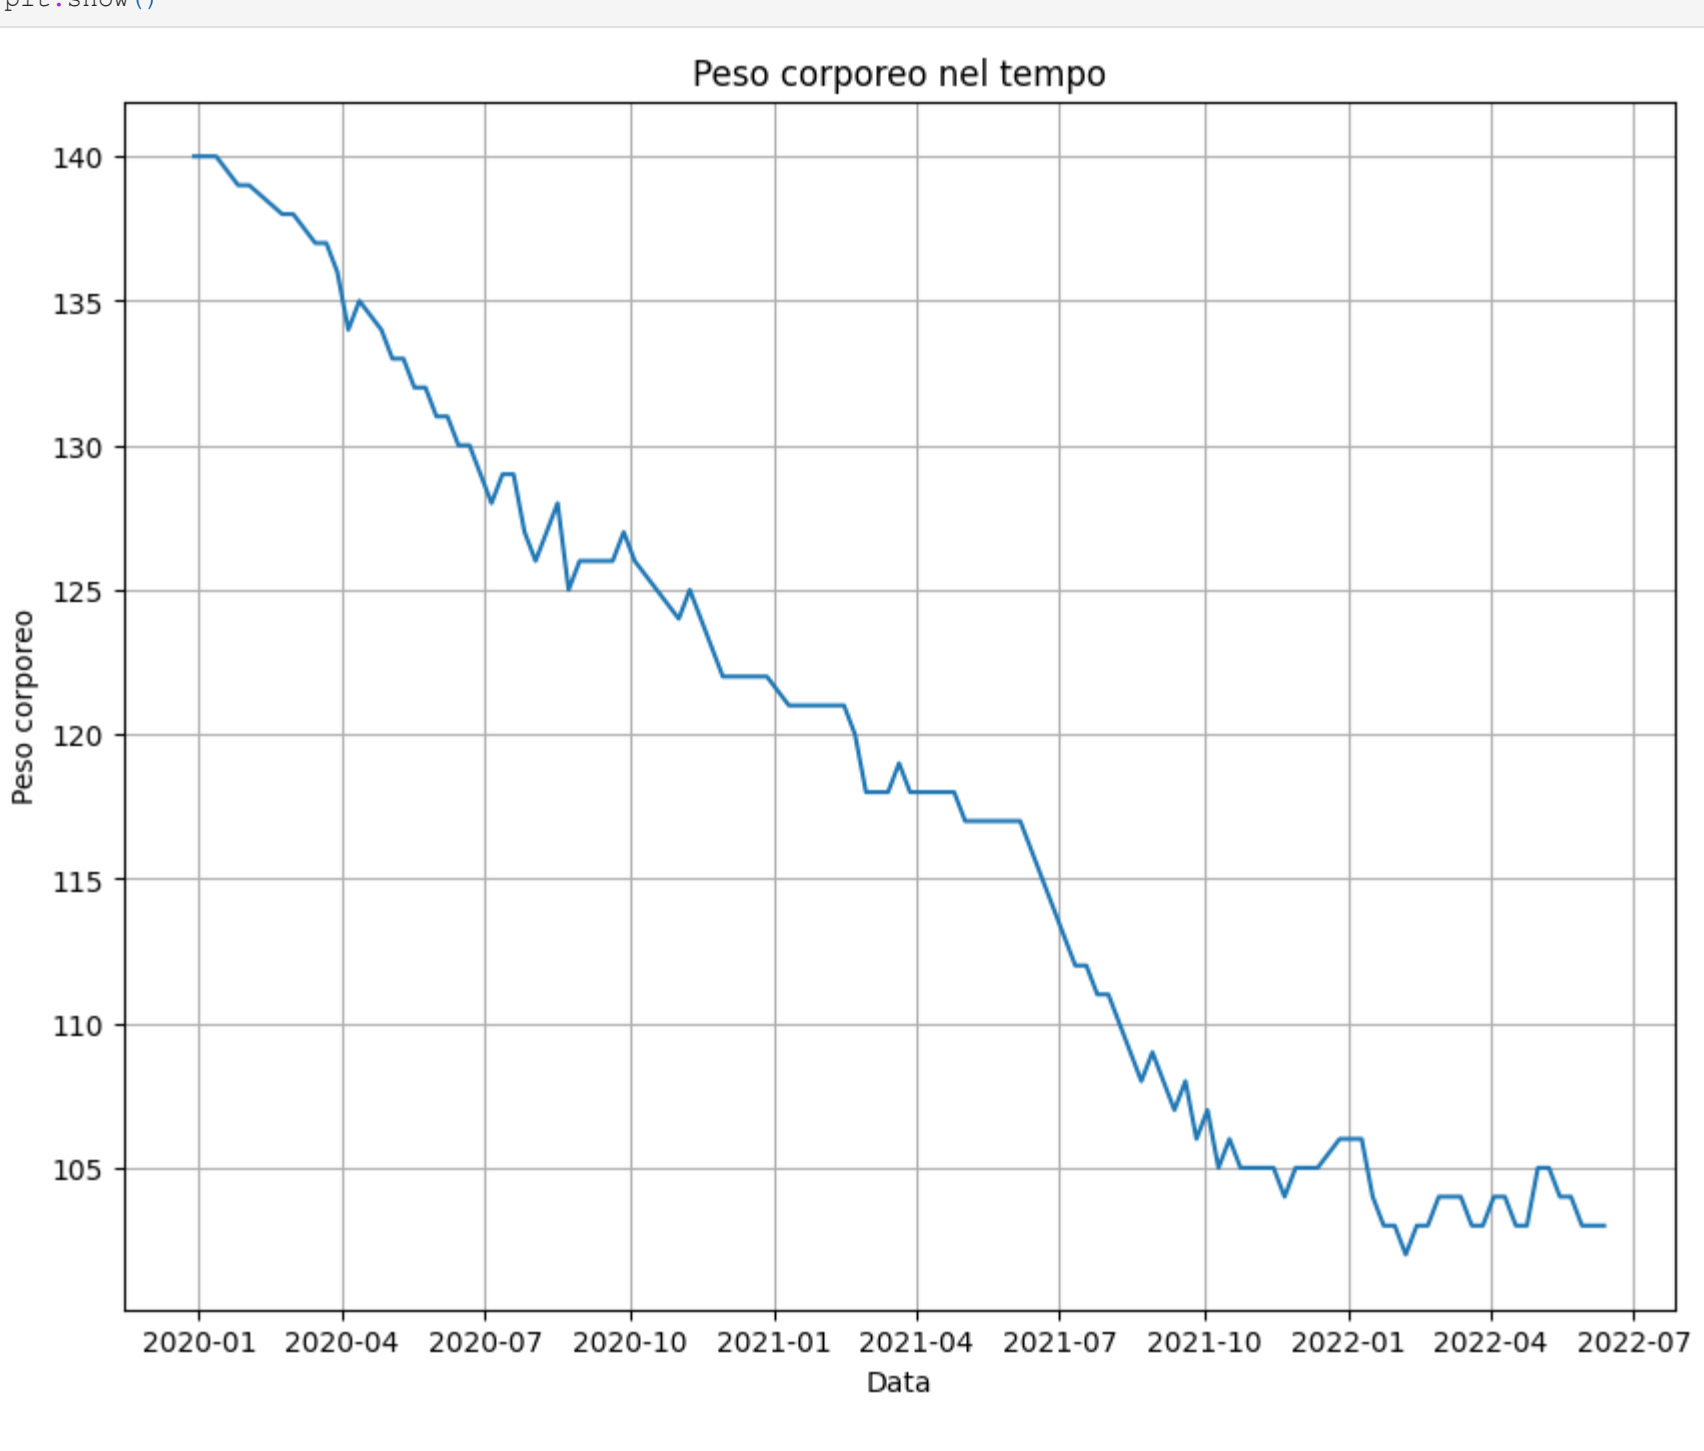

Sono state eliminate le settimane in cui non vi erano dati.

In [79]:
```
x = sorted(int(p) for p in df_peso['peso'])
n = len(x)
print(f'Ampiezza del dato: {n}')
for i, x_i in enumerate(x):
    print(f'x_({i + 1})={x_i}', end=' ')
```
```
Ampiezza del dato: 117
x_(1)=102 x_(2)=103 x_(3)=103 x_(4)=103 x_(5)=103 x_(6)=103 x_(7)=103 x_(8)=103 x_(9)=103 x_(10)=103 x_(11)=103
x_(12)=103 x_(13)=104 x_(14)=104 x_(15)=104 x_(16)=104 x_(17)=104 x_(18)=104 x_(19)=104 x_(20)=104 x_(21)=104 x
_(22)=105 x_(23)=105 x_(24)=105 x_(25)=105 x_(26)=105 x_(27)=105 x_(28)=105 x_(29)=105 x_(30)=105 x_(31)=105 x_
(32)=106 x_(33)=106 x_(34)=106 x_(35)=106 x_(36)=106 x_(37)=107 x_(38)=107 x_(39)=108 x_(40)=108 x_(41)=108 x_
(42)=109 x_(43)=109 x_(44)=110 x_(45)=111 x_(46)=111 x_(47)=112 x_(48)=112 x_(49)=113 x_(50)=114 x_(51)=115 x_
(52)=116 x_(53)=117 x_(54)=117 x_(55)=117 x_(56)=117 x_(57)=117 x_(58)=117 x_(59)=118 x_(60)=118 x_(61)=118 x_
(62)=118 x_(63)=118 x_(64)=118 x_(65)=118 x_(66)=118 x_(67)=119 x_(68)=120 x_(69)=121 x_(70)=121 x_(71)=121 x_
(72)=121 x_(73)=122 x_(74)=122 x_(75)=122 x_(76)=122 x_(77)=122 x_(78)=123 x_(79)=124 x_(80)=124 x_(81)=125 x_
(82)=125 x_(83)=125 x_(84)=126 x_(85)=126 x_(86)=126 x_(87)=126 x_(88)=126 x_(89)=126 x_(90)=127 x_(91)=127 x_
(92)=127 x_(93)=128 x_(94)=128 x_(95)=129 x_(96)=129 x_(97)=129 x_(98)=130 x_(99)=130 x_(100)=131 x_(101)=131 x
_(102)=132 x_(103)=132 x_(104)=133 x_(105)=133 x_(106)=134 x_(107)=134 x_(108)=135 x_(109)=136 x_(110)=137 x_(1
11)=137 x_(112)=138 x_(113)=138 x_(114)=139 x_(115)=139 x_(116)=140 x_(117)=140
```

Costruzione della tabella delle frequenze

Calcolo delle modalità

In [80]:
```
v_x = [x[0]]
for i in range(1, len(x)):
    if v_x[-1] != x[i]:
        v_x.append(x[i])

k_x = len(v_x)
print(f'Numero di modalità: {k_x}')

for i, v_i in enumerate(v_x):
    print(f'v_{i + 1}={v_i}', end=' ')
```
```
Numero di modalità: 39
v_1=102 v_2=103 v_3=104 v_4=105 v_5=106 v_6=107 v_7=108 v_8=109 v_9=110 v_10=111 v_11=112 v_12=113 v_13=114 v_1
4=115 v_15=116 v_16=117 v_17=118 v_18=119 v_19=120 v_20=121 v_21=122 v_22=123 v_23=124 v_24=125 v_25=126 v_26=1
27 v_27=128 v_28=129 v_29=130 v_30=131 v_31=132 v_32=133 v_33=134 v_34=135 v_35=136 v_36=137 v_37=138 v_38=139
v_39=140
```

Calcolo della frequenza assoluta delle modalità

Dalle frequenze assolute si può notare quando si è avuto più difficoltà nella perdita del peso o quando si era stabilizzato per un periodo di tempo.

In [81]:
```
f_x = [1]
for i in range(1, n):
    if x[i - 1] == x[i]:
        f_x[-1] += 1
    else:
        f_x.append(1)

for i, f_i in enumerate(f_x):
    print(f'f_{i + 1}={f_i}', end=' ')
```
```
f_1=1 f_2=11 f_3=9 f_4=10 f_5=5 f_6=2 f_7=3 f_8=2 f_9=1 f_10=2 f_11=2 f_12=1 f_13=1 f_14=1 f_15=1 f_16=6 f_17=8
f_18=1 f_19=1 f_20=4 f_21=5 f_22=1 f_23=2 f_24=3 f_25=6 f_26=3 f_27=2 f_28=3 f_29=2 f_30=2 f_31=2 f_32=2 f_33=2
f_34=1 f_35=1 f_36=2 f_37=2 f_38=2 f_39=2
```

Calcolo della frequenza cumulativa assoluta delle modalità

In [82]:
```
F_x = [f_x[0]]
for i in range(1, k_x):
    # Uso della relazione di ricorrenza
    F_x.append(F_x[-1] + f_x[i])

for i, F_i in enumerate(F_x):
    print(f'F_{i + 1}={F_i}', end=' ')
```
```
F_1=1 F_2=12 F_3=21 F_4=31 F_5=36 F_6=38 F_7=41 F_8=43 F_9=44 F_10=46 F_11=48 F_12=49 F_13=50 F_14=51 F_15=52 F
_16=58 F_17=66 F_18=67 F_19=68 F_20=72 F_21=77 F_22=78 F_23=80 F_24=83 F_25=89 F_26=92 F_27=94 F_28=97 F_29=99
F_30=101 F_31=103 F_32=105 F_33=107 F_34=108 F_35=109 F_36=111 F_37=113 F_38=115 F_39=117
```

Calcolo della frequenza relativa delle modalità

In [83]:
```
p_x = []
for f_i in f_x:
    p_x.append(f_i / n)

for i, p_i in enumerate(p_x):
    print(f'p_{i + 1}={p_i:.3f}', end=' ')
```
```
p_1=0.009 p_2=0.094 p_3=0.077 p_4=0.085 p_5=0.043 p_6=0.017 p_7=0.026 p_8=0.017 p_9=0.009 p_10=0.017 p_11=0.017
p_12=0.009 p_13=0.009 p_14=0.009 p_15=0.009 p_16=0.051 p_17=0.068 p_18=0.009 p_19=0.009 p_20=0.034 p_21=0.043 p
_22=0.009 p_23=0.017 p_24=0.026 p_25=0.051 p_26=0.026 p_27=0.017 p_28=0.026 p_29=0.017 p_30=0.017 p_31=0.017 p_
32=0.017 p_33=0.017 p_34=0.009 p_35=0.009 p_36=0.017 p_37=0.017 p_38=0.017 p_39=0.017
```

Calcolo della frequenza cumulativa relativa delle modalità

In [84]:
```
P_x = []
for F_i in F_x:
    P_x.append(F_i / n)

for i, P_i in enumerate(P_x):
    print(f'P_{i + 1}={P_i:.3f}', end=' ')
```
```
P_1=0.009 P_2=0.103 P_3=0.179 P_4=0.265 P_5=0.308 P_6=0.325 P_7=0.350 P_8=0.368 P_9=0.376 P_10=0.393 P_11=0.410
P_12=0.419 P_13=0.427 P_14=0.436 P_15=0.444 P_16=0.496 P_17=0.564 P_18=0.573 P_19=0.581 P_20=0.615 P_21=0.658 P
_22=0.667 P_23=0.684 P_24=0.709 P_25=0.761 P_26=0.786 P_27=0.803 P_28=0.829 P_29=0.846 P_30=0.863 P_31=0.880 P_
32=0.897 P_33=0.915 P_34=0.923 P_35=0.932 P_36=0.949 P_37=0.966 P_38=0.983 P_39=1.000
```

Tabella delle frequenze

In [85]:
```
data_table = []
for i in range(k_x):
    data_table.append([i + 1, v_x[i], f_x[i], p_x[i], F_x[i], P_x[i]])

df_data_table = pd.DataFrame(data_table, columns=['i', 'v_i', 'f_i', 'p_i', 'F_i', 'P_i'])
df_data_table.set_index('i', inplace=True)
df_data_table
```

Out[85]:

i	v_i	f_i	p_i	F_i	P_i
1	102	1	0.008547	1	0.008547
2	103	11	0.094017	12	0.102564
3	104	9	0.076923	21	0.179487
4	105	10	0.085470	31	0.264957
5	106	5	0.042735	36	0.307692
6	107	2	0.017094	38	0.324786
7	108	3	0.025641	41	0.350427
8	109	2	0.017094	43	0.367521
9	110	1	0.008547	44	0.376068
10	111	2	0.017094	46	0.393162
11	112	2	0.017094	48	0.410256
12	113	1	0.008547	49	0.418803
13	114	1	0.008547	50	0.427350
14	115	1	0.008547	51	0.435897
15	116	1	0.008547	52	0.444444
16	117	6	0.051282	58	0.495726
17	118	8	0.068376	66	0.564103
18	119	1	0.008547	67	0.572650
19	120	1	0.008547	68	0.581197
20	121	4	0.034188	72	0.615385
21	122	5	0.042735	77	0.658120
22	123	1	0.008547	78	0.666667
23	124	2	0.017094	80	0.683761
24	125	3	0.025641	83	0.709402
25	126	6	0.051282	89	0.760684
26	127	3	0.025641	92	0.786325
27	128	2	0.017094	94	0.803419
28	129	3	0.025641	97	0.829060
29	130	2	0.017094	99	0.846154
30	131	2	0.017094	101	0.863248
31	132	2	0.017094	103	0.880342
32	133	2	0.017094	105	0.897436
33	134	2	0.017094	107	0.914530
34	135	1	0.008547	108	0.923077
35	136	1	0.008547	109	0.931624
36	137	2	0.017094	111	0.948718
37	138	2	0.017094	113	0.965812
38	139	2	0.017094	115	0.982906
39	140	2	0.017094	117	1.000000

Grafici distribuzione delle frequenze assolute

Grafico a linee

In [86]:
```
fig, ax = plt.subplots()
ax.plot(v_x, f_x, '-o')
ax.set_title('Distribuzione delle frequenze assolute')
ax.set_xlabel(r'$v_i$')
ax.set_ylabel(r'$f_i$')
ax.grid()

for i, v_i in enumerate(v_x):
    ax.text(v_i, f_x[i], f'{f_x[i]:.0f}', ha='left', va='bottom')

plt.show()
```

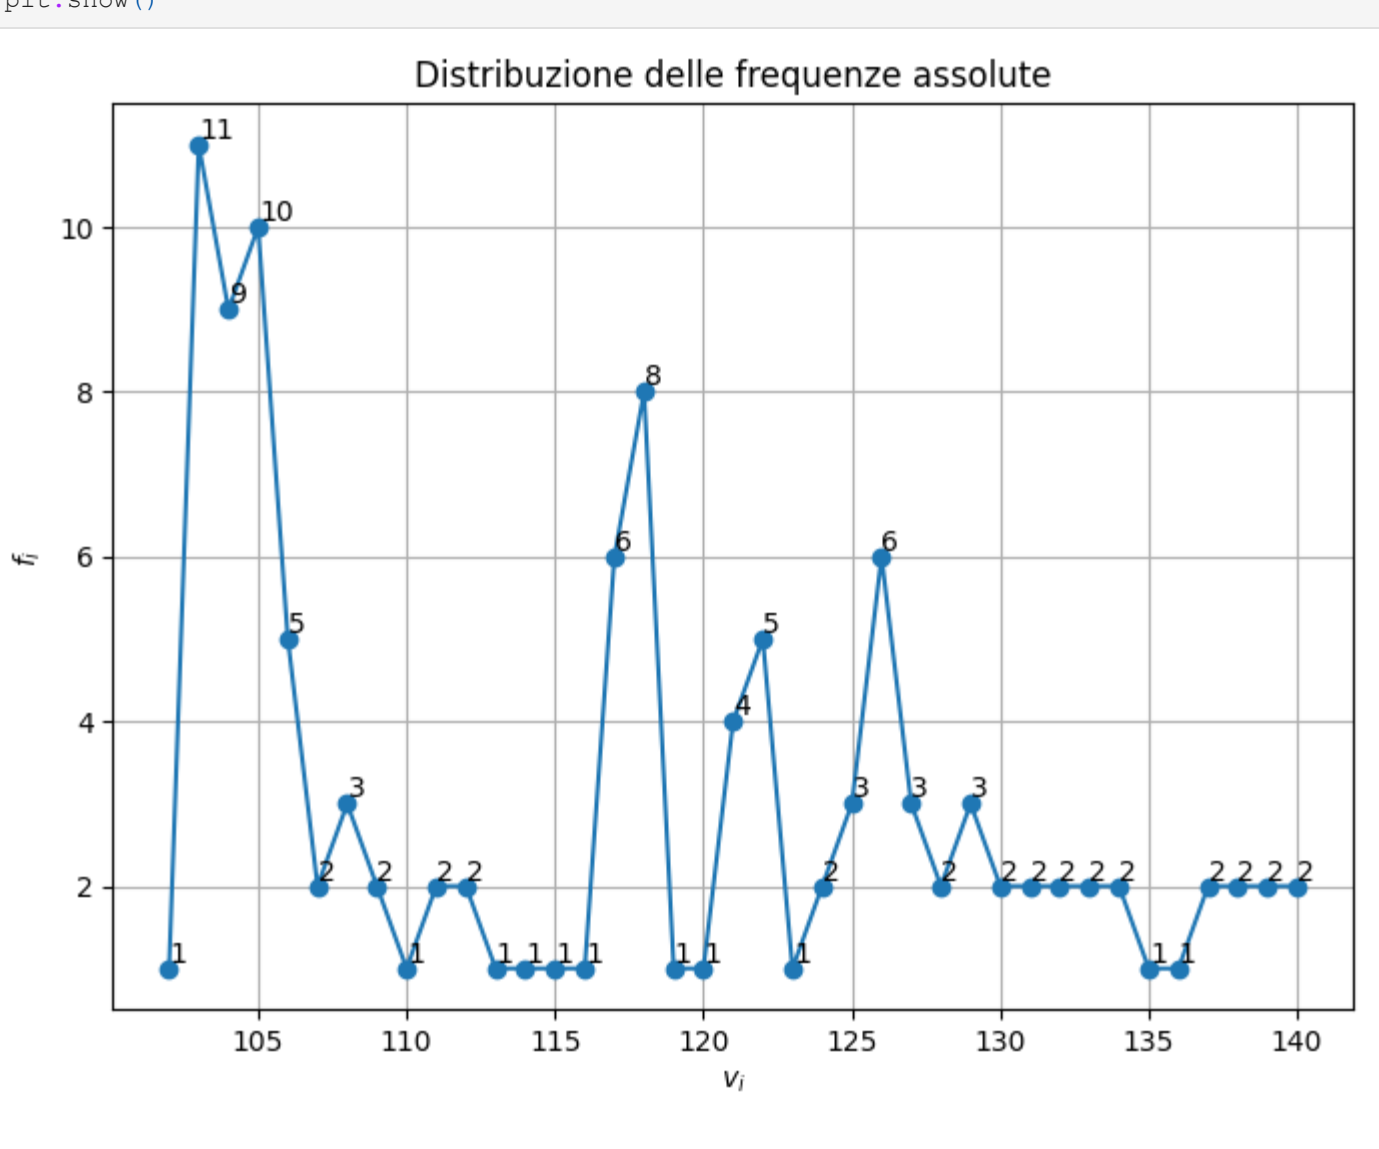

Istogramma

In [87]:
```
def plot_histogram_classe(ampiezza_classe):
    min_value = x[0]
    max_value = x[n - 1]

    fig, ax = plt.subplots()
    values, bins, bars = ax.hist(x, bins=list(range(min_value, max_value + ampiezza_classe, ampiezza_classe)), 

    ax.set_xticks(bins)
    ax.bar_label(bars)
    ax.set_title(f'Distribuzione delle frequenze assolute con classe di ampiezza {ampiezza_classe}')
    ax.set_xlabel(r'$v_i$')
    ax.set_ylabel(r'$f_i$')

    plt.show()
```

In [88]:
```
plot_histogram_classe(3)
```

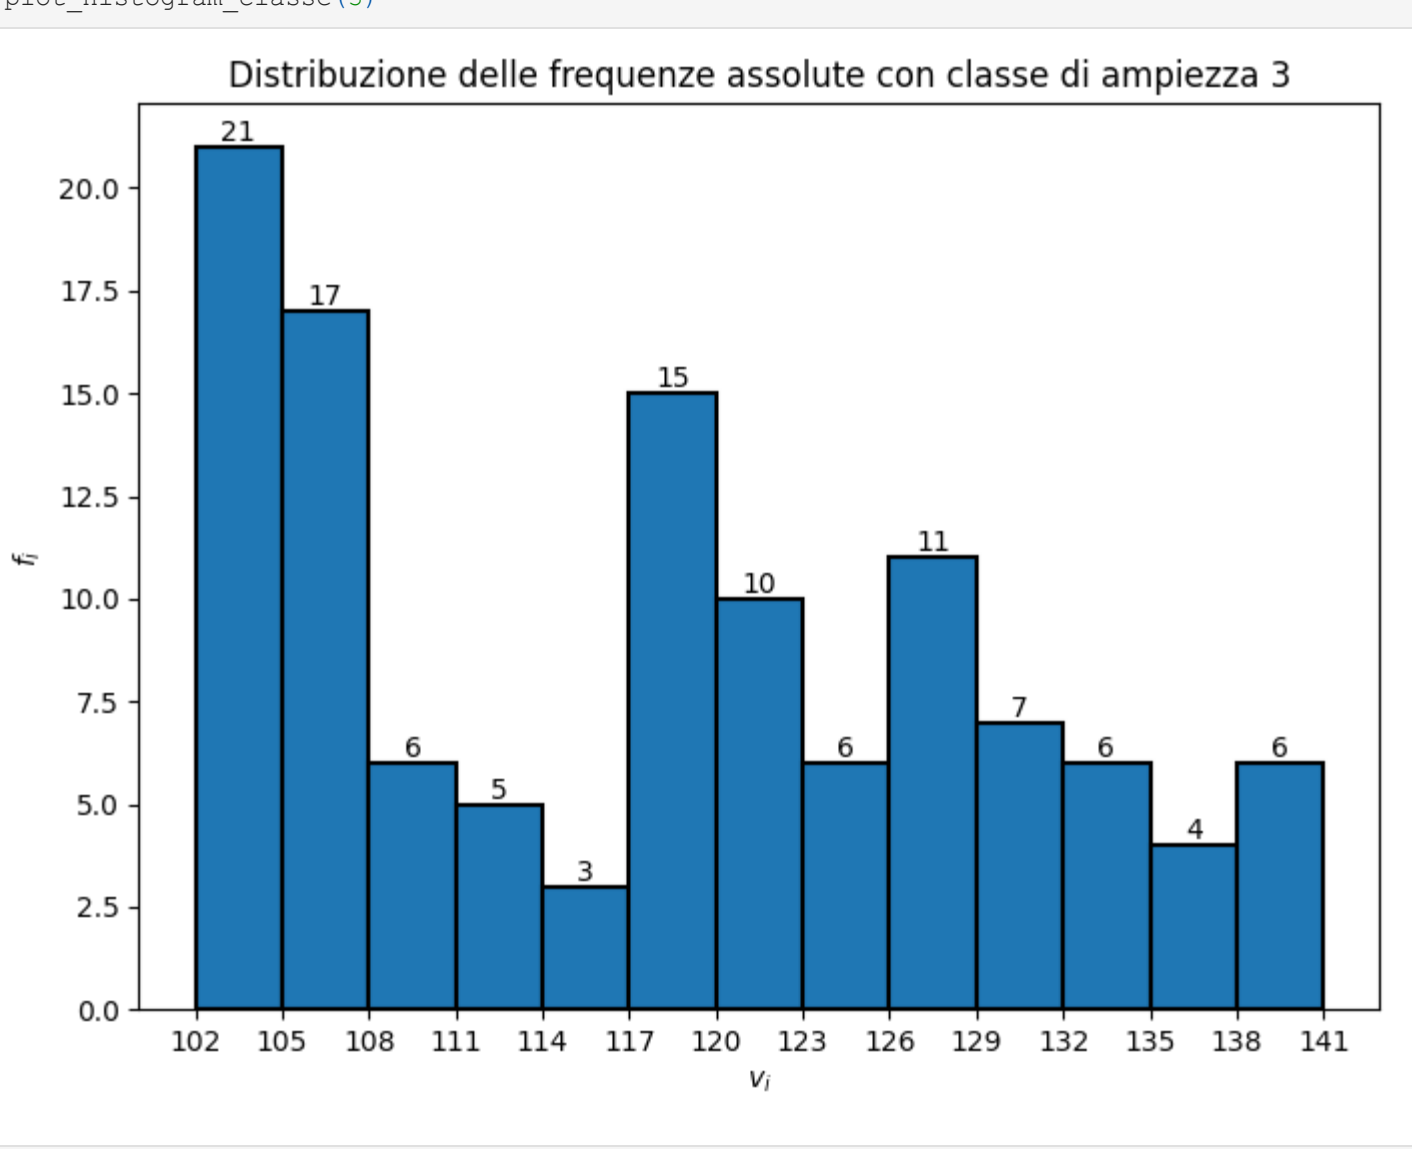

In [89]:
```
plot_histogram_classe(5)
```

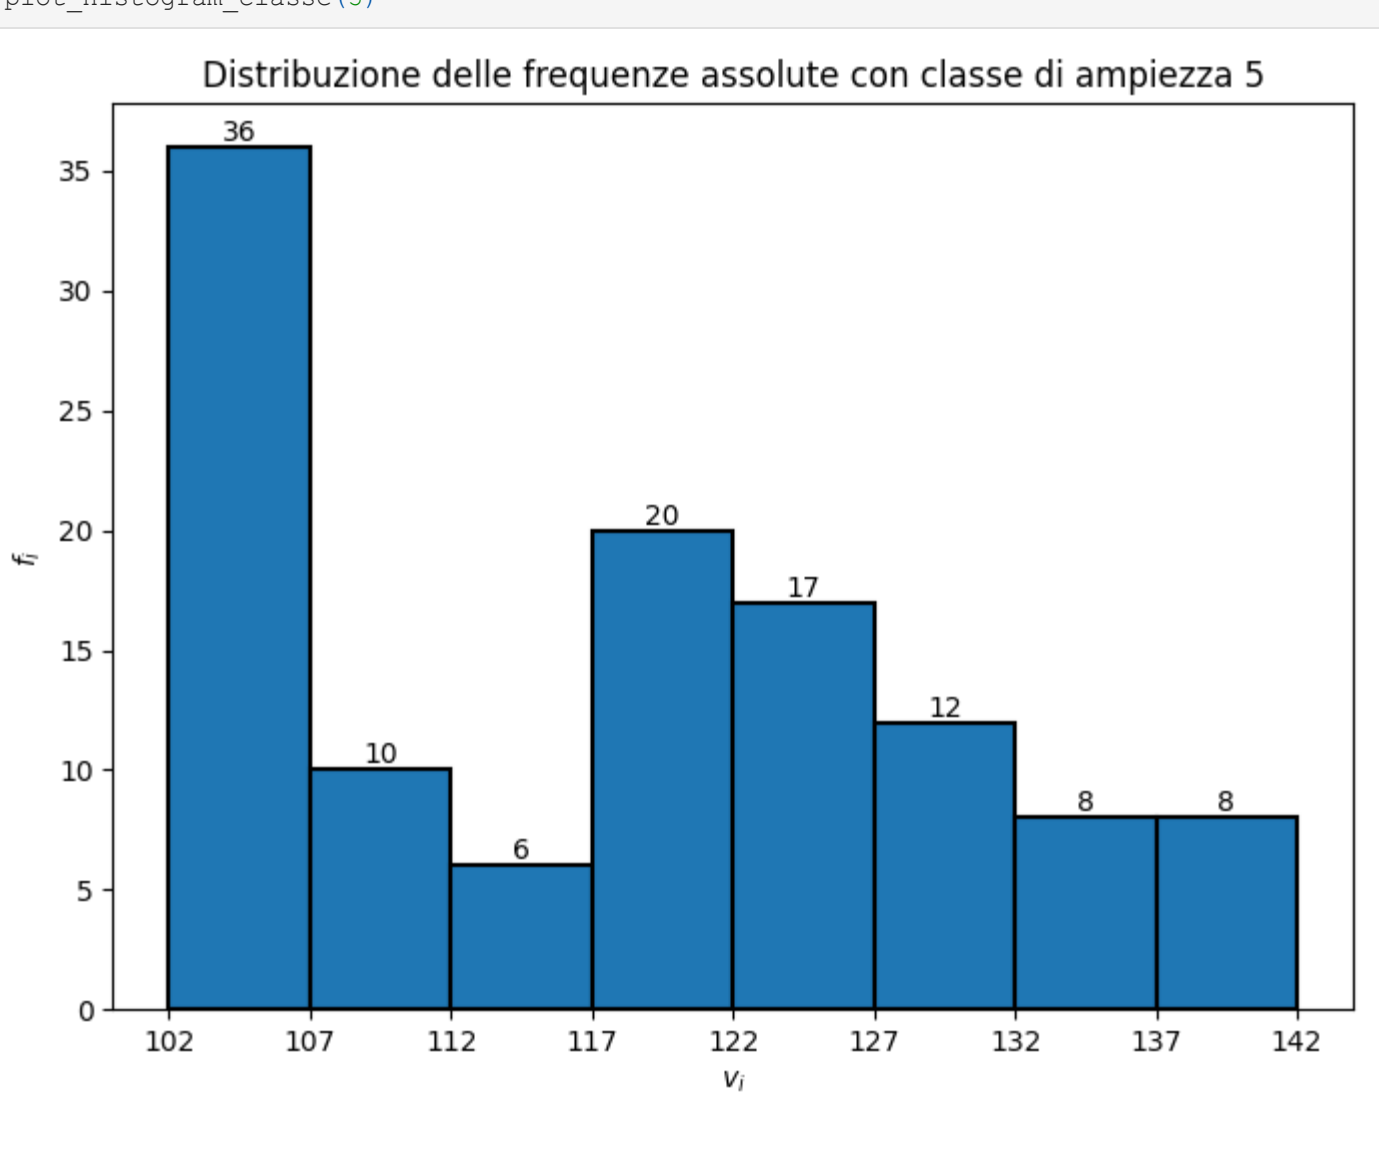

Indici di posizione

Calcolo della media campionaria

L'indice della media campionare su tutto il campione è poco significativo in questo campione perché, come si nota dal grafico dal peso corporeo nel tempo, il peso sempre sceso e quindi i valori sono cambiati spesso. La media campionaria invece indicherebbe che si è avuto una media di peso corporeo per ogni settimana di 117 kg, cosa non vera.

In [90]:
```
x_mean = 0
for x_i in x:
    x_mean += x_i
x_mean = x_mean / n

print(f'Media campionaria: {x_mean}')
```
```
Media campionaria: 117.3076923076923
```

Calcolo della media pesata

In [91]:
```
x_mean_pesata = 0
for i in range(k_x):
    x_mean_pesata += (f_x[i] / n) * v_x[i]

print(f'Media pesata: {x_mean_pesata}')
```
```
Media pesata: 117.30769230769238
```

Calcolo della mediana campionaria

Anche la mediana campionaria per la tipologia del dato, è poco signficativa.

In [92]:
```
if n % 2 == 0:
    x_mediana = (x[n // 2] + x[n // 2 - 1]) / 2
else:
    x_mediana = x[n // 2]

print(f'Mediana campionaria: {x_mediana}')
```
```
Mediana campionaria: 118
```

Calcolo della moda campionaria

La moda campionaria è molto utile, in quanto come detto precedentemente, si riesce a determinare in quali fasi del peso corporeo si è avuto più difficoltà. Calcolando più mode campionarie, escludendo ogni volta quella precedente, si riesce a capire quali sono le fasi del peso corporeo in cui si è avuto più difficoltà.

In [93]:
```
max_f_x = 0
index = 0
count = 0

for i, f_i in enumerate(f_x):
    if f_i > max_f_x:
        max_f_x = f_i
        count = 1
        index = i
    elif f_i == max_f_x:
        count += 1

x_moda = v_x[index]
if count == 1:
    print(f'Moda campionaria unimodale: v_{index + 1} = {x_moda}, f_{index + 1} = {max_f_x}')
elif count == 2:
    print(f'Moda campionaria bimodale: v_{index + 1} = {x_moda}, f_{index + 1} = {max_f_x}')
else:
    print(f'Moda campionaria multimodale: v_{index + 1} = {x_moda}, f_{index + 1} = {max_f_x}')
```
```
Moda campionaria unimodale: v_2 = 103, f_2 = 11
```

Indici di variabilità

Calcolo della varianza campionaria

La varianza dei dati rispetto alla media campionaria è un po' alta.

In [94]:
```
s2_x = 0
for x_i in x:
    s2_x += (x_i - x_mean) ** 2

s2_x = s2_x / (n - 1)
print(f'Varianza campionaria: {s2_x}')
```
```
Varianza campionaria: 132.473474801061
```

Calcolo della deviazione standard campionaria

In [95]:
```
s_x = sqrt(s2_x)
print(f'Deviazione standard campionaria: {s_x}')
```
```
Deviazione standard campionaria: 11.509712194536448
```

Calcolo dello scarto medio assoluto

In [96]:
```
sa_x = 0
for x_i in x:
    sa_x += abs(x_i - x_mean)

sa_x = sa_x / n
print(f'Scarto medio assoluto: {sa_x}')
```
```
Scarto medio assoluto: 9.92899408284025
```

Calcolo dell'ampiezza del campo di variazione

Questo dato indica anche il massimo di chili persi in tutto il periodo.

In [97]:
```
w_x = x[n - 1] - x[0]
print(f'Ampiezza del campo di variazione: {w_x}')
```
```
Ampiezza del campo di variazione: 38
```

Calcolo del coefficiente di variazione

In [98]:
```
cv_x = s_x / x_mean
print(f'Coefficiente di variazione: {cv_x}')
```
```
Coefficiente di variazione: 0.09811557936326153
```

Indici di forma

Calcolo dell'indice di simmetria

Dall'istogramma si nota una coda a destra, infatti l'indice è positivo.

In [99]:
```
g_x = 0
for x_i in x:
    g_x += (x_i - x_mean) ** 3

g_x = g_x / n
g_x = g_x / (s_x ** 3)

if g_x < 0:
    print(f'Indice di simmetria: {g_x}, asimmetria negativa')
else:
    print(f'Indice di simmetria: {g_x}, asimmetria positiva')
```
```
Indice di simmetria: 0.27065848440992524, asimmetria positiva
```

In [100…
```
plot_histogram_classe(1)
```

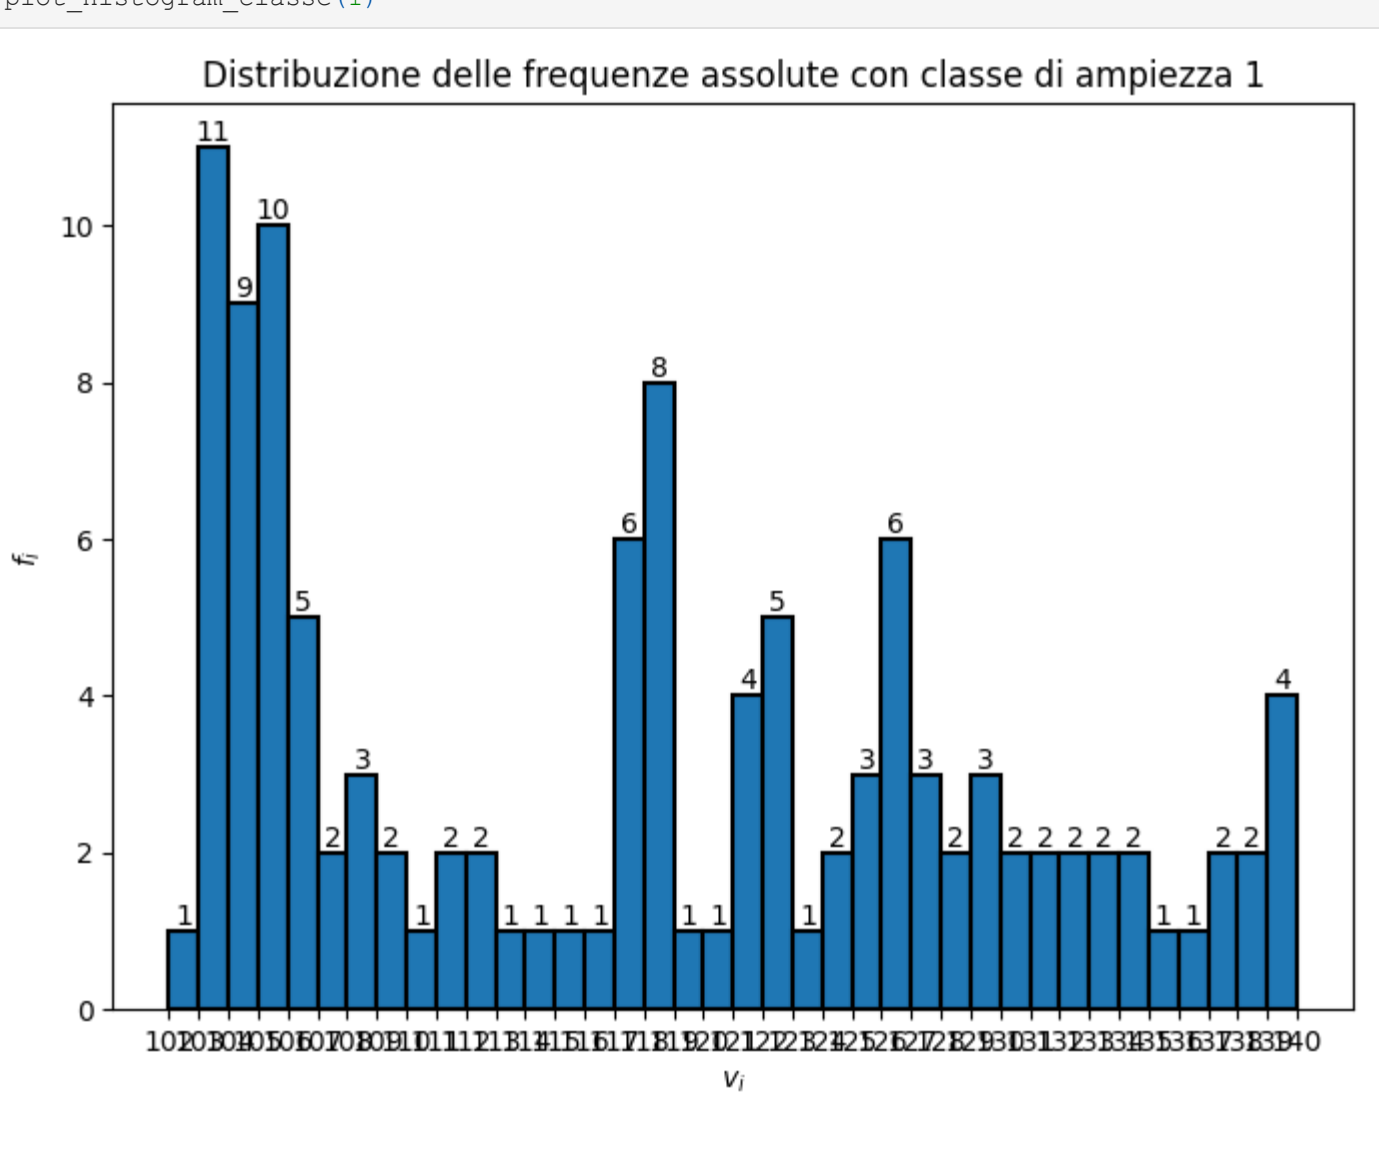

Calcolo dell'indice di curtosi

In [101…
```
curtosi_x = 0
for x_i in x:
    curtosi_x += (x_i - x_mean) ** 4

curtosi_x = curtosi_x / n
curtosi_x = curtosi_x / (s_x ** 4)
curtosi_x = curtosi_x - 3

if curtosi_x > 0:
    print(f'Indice di curtosi: {curtosi_x}, è presente un eccesso di dati nelle classi centrali')
elif curtosi_x < 0:
    print(f'Indice di curtosi: {curtosi_x}, è presente una carenza di dati nelle classi centrali')
else:
    print(f'Indice di curtosi: {curtosi_x}, è presente una distribuzione di dati come quella di una distribuzio
```
```
Indice di curtosi: -1.2046113925538144, è presente una carenza di dati nelle classi centrali
```

Quartili

Calcolo dei quartili

In [102…
```
def get_quartile(k):
    np = n * (k / 100)
    if np % 1 == 0:
        return (x[int(np)] + x[int(np) - 1]) / 2
    else:
        return x[int(np)]
```

In [103…
```
Q1_x = get_quartile(25)
Q2_x = get_quartile(50)
Q3_x = get_quartile(75)

print(f'Principali quartili: Q1 = {Q1_x}, Q2 = {Q2_x}, Q3 = {Q3_x}')
```
```
Principali quartili: Q1 = 105, Q2 = 118, Q3 = 126
```

Calcolo dello scarto interquartile

Indica la lunghezza del rettangolo nel box plot

In [104…
```
si_x = Q3_x - Q1_x
print(f'Scarto interquartile: {si_x}')
```
```
Scarto interquartile: 21
```

Box plot

Come si evince dal grafico, non vi sono outliers. Se essi fosse presenti, sarebbero indicati nel grafico come dei punti rossi. Il segmento arancione rappresenta la media campionaria.

In [105…
```
fig, ax = plt.subplots(figsize=(10, 8))
ax.boxplot(x, flierprops=dict(marker='s', markerfacecolor='red'))
ax.set_title('Box plot')
ax.yaxis.set_ticks_position('none')
ax.grid(axis='y', linestyle='-', linewidth=0.5, color='lightgrey')
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
ax.spines['left'].set_visible(False)
ax.get_xaxis().set_visible(False)
plt.show()
```

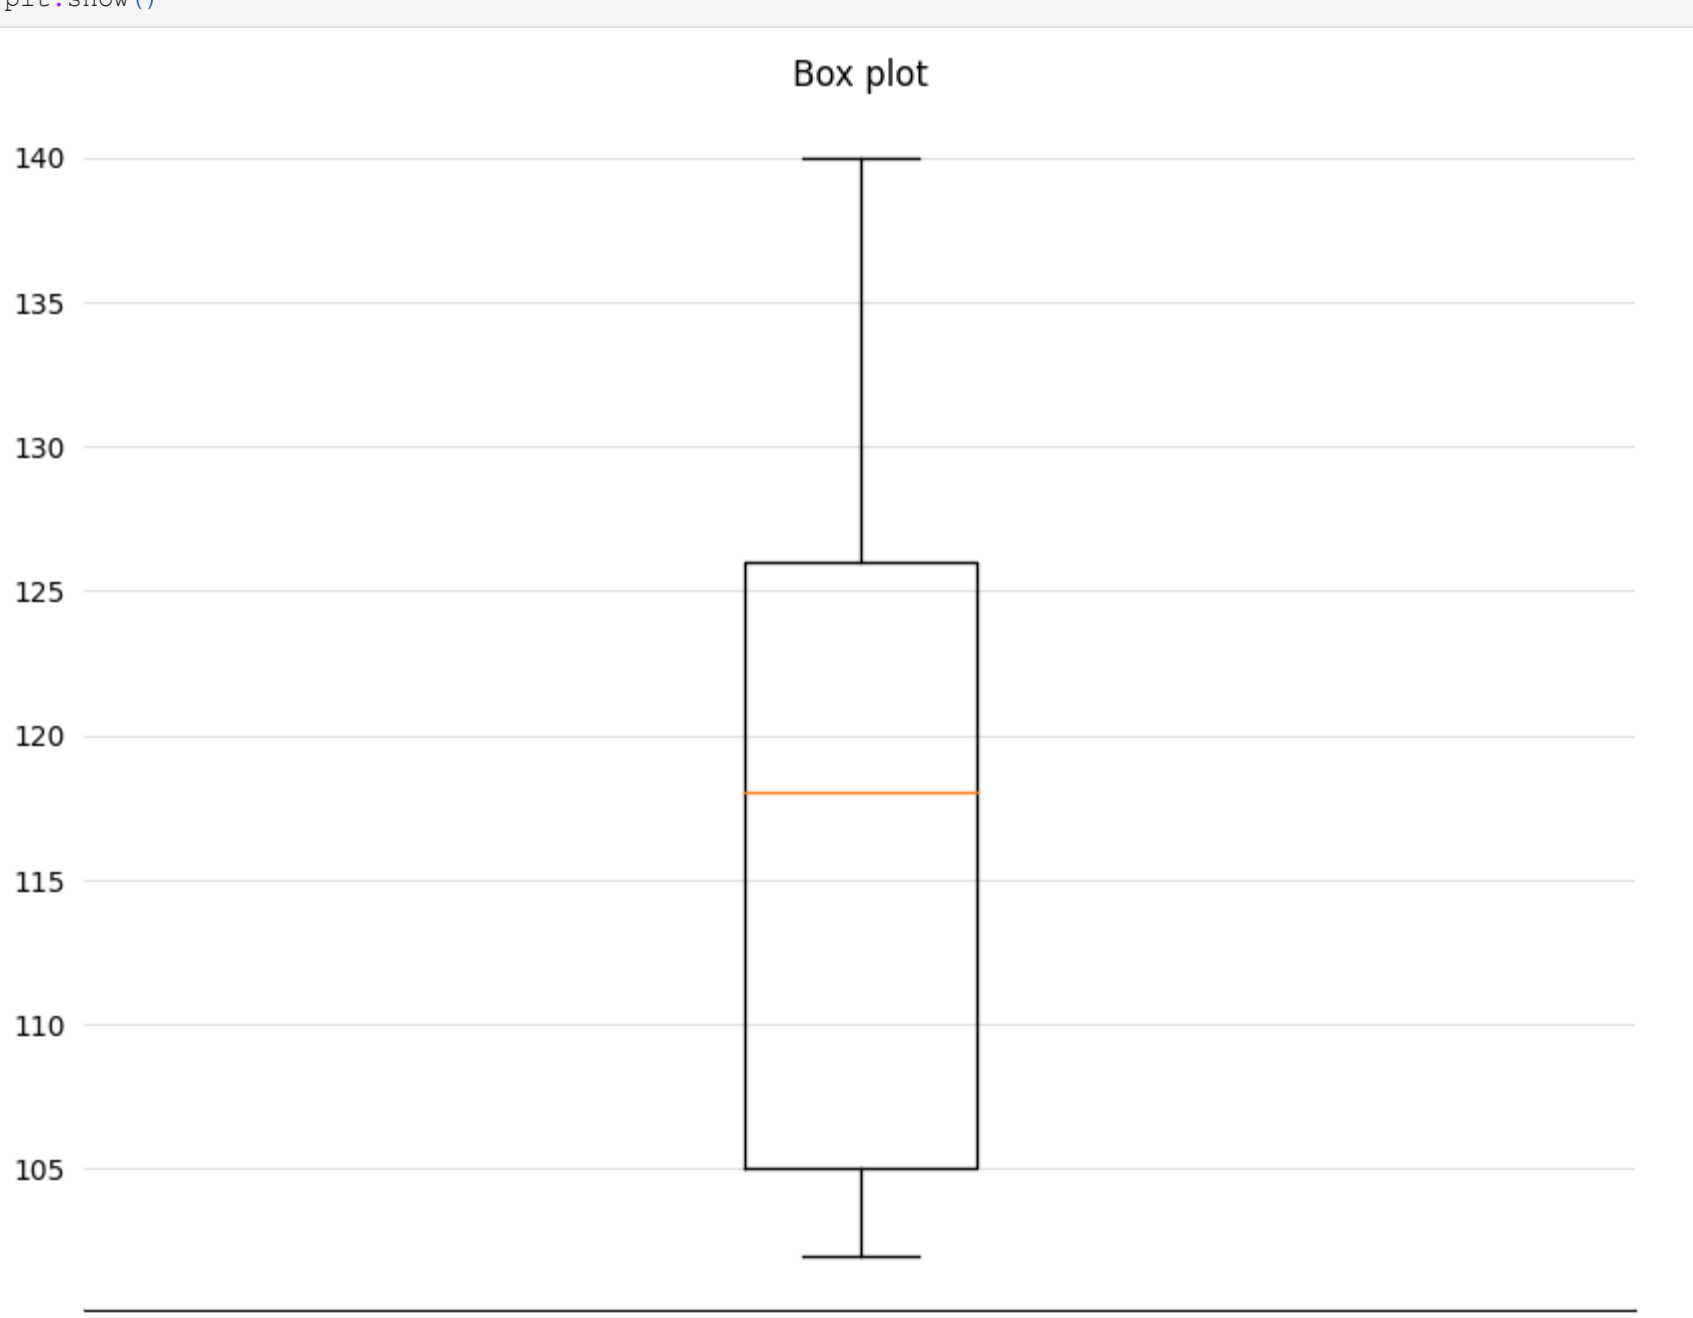

Intervalli di previsione

Gli intervalli di previsione non sono quelli tipici di una distribuzione normale, ma questo lo si poteva già evincere dall'istogramma delle classi di ampiezza 1.

In [106…
```
intervallo1_x = (x_mean - s_x, x_mean + s_x)
intervallo2_x = (x_mean - 2 * s_x, x_mean + 2 * s_x)
intervallo3_x = (x_mean - 3 * s_x, x_mean + 3 * s_x)

count1 = 0
count2 = 0
count3 = 0
for x_i in x:
    if intervallo1_x[0] < x_i < intervallo1_x[1]:
        count1 += 1
    if intervallo2_x[0] < x_i < intervallo2_x[1]:
        count2 += 1
    if intervallo3_x[0] < x_i < intervallo3_x[1]:
        count3 += 1

print(f'Intervalli di previsione:\n{intervallo1_x} {(count1 / n) * 100:.2f}%\n{intervallo2_x} {(count2 / n) * 1
```
```
Intervalli di previsione:
(105.79798011315586, 128.81740450222875) 53.85%
(94.28826791861941, 140.3271166967652) 100.00%
(82.77855572408296, 151.83682889130165) 100.00%
```

Parsing dei dati delle calorie assunte

In [107…
```
with open('calorie.csv', 'r') as csvfile:
    reader = csv.reader(csvfile, delimiter=',')
    calorie = []
    reader.__next__()
    reader.__next__()
    for row in reader:
        calorie.append([row[0], float(row[8])])

df_calorie = pd.DataFrame(calorie, columns=['data', 'calorie'])
df_calorie['data'] = pd.to_datetime(df_calorie['data'])
df_calorie = df_calorie.groupby(pd.Grouper(key='data', freq='D')).sum().round(0)
df_calorie = df_calorie.reset_index()
df_calorie = df_calorie.groupby(pd.Grouper(key='data', freq='W')).mean().round(0)
df_calorie = df_calorie.reset_index()
print(f'Numero di ampiezza dei dati prima della eliminazione delle settimane in cui non vi sono state pesate co
df_calorie
```

```
Numero di ampiezza dei dati prima della eliminazione delle settimane in cui non vi sono state pesate corporee: 139
```

Out[107]:

	data	calorie
0	2019-10-20	2374.0
1	2019-10-27	1768.0
2	2019-11-03	1291.0
3	2019-11-10	1875.0
4	2019-11-17	1702.0
...	...	...
134	2022-05-15	1894.0
135	2022-05-22	1727.0
136	2022-05-29	1780.0
137	2022-06-05	1808.0
138	2022-06-12	2099.0

139 rows × 2 columns

In [108_

```
fig, ax = plt.subplots(figsize=(10, 8))
ax.plot(df_calorie['data'], df_calorie['calorie'])
ax.set_title('Calorie assunte nel tempo')
ax.set_xlabel('Data')
ax.set_ylabel('Calorie assunte')
ax.grid()
plt.show()
```

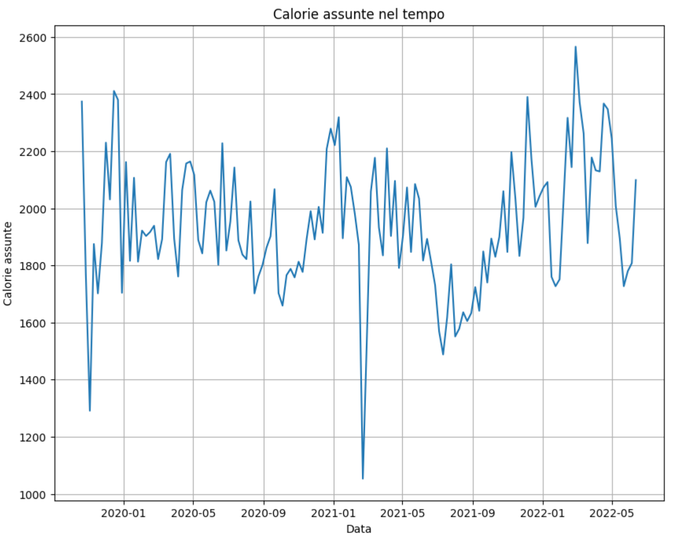

In [109_

```
df_merge = pd.merge(df_peso, df_calorie, on='data', how='inner')
df_merge = df_merge.dropna()
df_merge = df_merge.reset_index()

print(f'Numero di ampiezza dei dati dopo l\'eliminazione delle settimane in cui non vi sono state pesate corpor
df_merge
```

```
Numero di ampiezza dei dati dopo l'eliminazione delle settimane in cui non vi sono state pesate corporee: 117
```

Out[109]:

	index	data	peso	calorie
0	0	2019-12-29	140.0	1704.0
1	1	2020-01-12	140.0	1816.0
2	2	2020-01-26	139.0	1813.0
3	3	2020-02-02	139.0	1922.0
4	4	2020-02-23	138.0	1939.0
...	...	...	...	...
112	112	2022-05-15	104.0	1894.0
113	113	2022-05-22	104.0	1727.0
114	114	2022-05-29	103.0	1780.0
115	115	2022-06-05	103.0	1808.0
116	116	2022-06-12	103.0	2099.0

117 rows × 4 columns

Dati bidimensionali

Calcolo dei coefficienti di correlazione campionario

In [110_

```
n = len(df_merge)
peso_mean = df_merge['peso'].mean()
calorie_mean = df_merge['calorie'].mean()
s_peso = df_merge['peso'].std()
s_calorie = df_merge['calorie'].std()

r = 0
for i in range(n):
    r += (df_merge['peso'][i] - peso_mean) * (df_merge['calorie'][i] - calorie_mean)
r = r / ((n - 1) * s_peso * s_calorie)

if r > 0:
    print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione positiva')
elif r < 0:
    print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione negativa')
else:
    print(f'Coefficiente di correlazione campionario: {r}, è presente una correlazione nulla')
```

```
Coefficiente di correlazione campionario: -0.10148784794747004, è presente una correlazione negativa
```

Diagramma a dispersione (scatter plot)

In [111_

```
fig, ax = plt.subplots(figsize=(10, 8))
ax.scatter(df_merge['peso'], df_merge['calorie'])
ax.set_xlabel('Peso')
ax.set_ylabel('Calorie assunte')

plt.show()
```

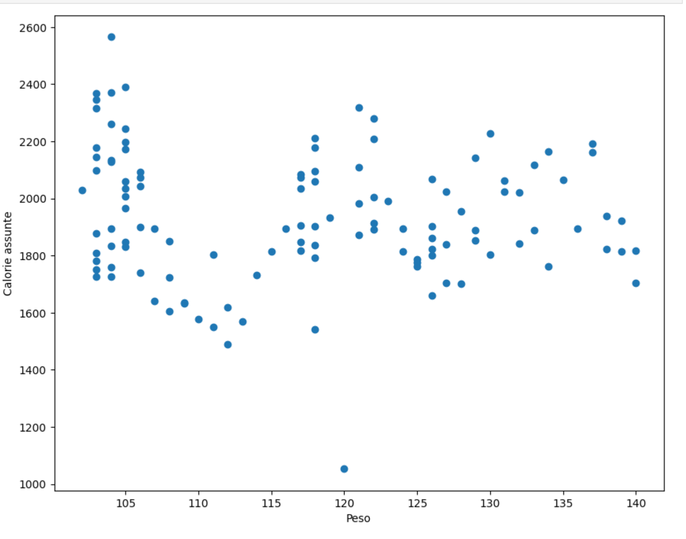

Quello che emerge dalla correlazione negativa tra il peso e le calorie è che quando il peso era alto vi era un minore consumo di calorie. Al diminuire del peso, le calorie assunte sono aumentate. In effetti nella realtà questo accadde e quindi si può trovare una delle cause della non diminuzione del peso. Tuttavia, le variabili sono molte, come ad esempio una maggiore attività fisica che ha portato allo sviluppo di massa muscolare e quindi alla contribuzione della non diminuzione del peso in generale.

Con i dati da Samsung Health si potrebbero fare molti altri studi, come ad esempio quanto ha influito l'attività fisica sul peso, come è cambiato il battito cardiaco e la pressione sanguigna (la pressione scese di molto), ecc. Con l'incrocio dei dati si potrebbero fare tante cose interessanti.